S14 – Documentación del laboratorio: esquema y carga desde CSV

1. Ubicación de los archivos

Archivo	Carpeta	Nota
01_esquema.sql	postgres/init/	Corre solo con la base vacía; empieza con DROP SCHEMA IF EXISTS biblioteca CASCADE; CREATE SCHEMA biblioteca;
S14-carga-libros.sql, S14-carga-lectores.sql	postgres/scripts/	Se corren a mano, repetibles
4 CSV semilla + S14_libros_propio_con_errores.csv	postgres/scripts/datos/	En el contenedor: /scripts/datos/…

Orden de prueba: esquema → libros limpio → lectores limpio → libros con errores → lectores con errores → CSV propio → libros limpio otra vez. **Los archivos con errores se cargan después de los limpios**: dos de sus filas (ISBN y documento repetidos) solo se detectan porque el registro original ya está en la base.

2. Mapeo CSV → esquema

El esquema propio no es una tabla por archivo: el libro se reparte en tres tablas y el lector es un usuario con rol Lector.

2.1 libros_*.csv

Columna del CSV	Tabla.columna destino	Transformación	Regla de validación (motivo)
(estructura)	—	string_to_array(linea, ',')	6 campos exactos (tiene N columnas, se esperaban 6)

isbn	libro.isbn (PK, VARCHAR(13)) y ejemplar.isbn	trim	no vacío (ISBN vacío); 13 dígitos (ISBN no tiene exactamente 13 dígitos); no existe en libro (ISBN ya existe en el catálogo); no repetido en el archivo (ISBN repetido en el archivo (línea N))
titulo	libro.titulo	trim	no vacío (título vacío)
autor	libro.autor	trim	no vacío (autor vacío)
categoria	categoria.nombre (UNIQUE) → libro.id_categoria	trim; alta con ON CONFLICT (nombre) DO NOTHING; el id se busca con JOIN	no vacía (categoría vacía)
anio_publicacion	libro.anio_publicacion (SMALLINT)	trim, ::SMALLINT	solo dígitos, 1–4 (año no numérico o con formato inválido); entre 1450 y 2100 (año fuera del rango 1450–2100)

ejemplares_disponibles	ejemplar (n filas: isbn, numero_copia 1..n; estado queda en 'disponible')	generate_series(1, n) en CROSS JOIN LATERAL	entero (cantidad de ejemplares no numérica o con formato inválido); ≥ 0 (cantidad de ejemplares negativa). Con 0 el libro entra sin copias

2.2 lectores_*.csv

Columna del CSV	Tabla.columna destino	Transformación	Regla de validación (motivo)
(estructura)	—	string_to_array	5 campos exactos
documento	usuario.documento (UNIQUE)	trim	no vacío (documento vacío); 6–15 dígitos (documento debe tener entre 6 y 15 dígitos); no existe (documento ya existe en el sistema); no repetido en el archivo (documento repetido en el archivo)
nombres	usuario.nombres	trim	no vacío (nombres vacíos)
apellidos	usuario.apellidos	trim	no vacío (apellidos vacíos)
correo	usuario.correo (UNIQUE)	lower(trim(...))	no vacío (correo vacío); formato algo@algo.algo sin espacios (formato de correo inválido); no existe, sin distinguir mayúsculas (correo ya existe en el sistema); no repetido en el archivo (correo repetido en el archivo)
telefono	usuario.telefono	trim; vacío → NULL con NULLIF	opcional; si viene, 7–15 dígitos (teléfono debe tener entre 7 y 15 dígitos)

(no viene en el CSV)	usuario.clave_hash	crypt(documento, gen_salt('bf')) (pgcrypto): el documento es la clave inicial, guardada solo como hash	—
(no viene en el CSV)	usuario.tipo_rol	constante 'Lector'	—

usuario.activo toma su DEFAULT TRUE. Las demás columnas de la bitácora (rechazo_carga) guardan archivo, línea, contenido original y motivo.

3. Criterios por tipo de error

Principio aplicado a todos los casos: **se corrige solo lo mecánico y sin ambigüedad** (espacios sobrantes con trim, correo en minúsculas, teléfono vacío como NULL); **se rechaza y se registra todo lo que habría que adivinar**; **un alta nunca pisa un registro existente** (no se usa ON CONFLICT DO UPDATE). El CASE guarda solo el primer motivo de cada fila.

#	Archivo · línea	Problema	Decisión	Motivo en la bitácora	Por qué
1	libros · 2	ISBN ya está en el catálogo (título distinto, 2 ejemplares)	Rechazar	ISBN ya existe en el catálogo	El archivo es de altas. No se sabe si el 2 son copias nuevas o un error, y el título difiere
2	libros · 3	Título vacío	Rechazar	título vacío	El dato falta y no se puede deducir
3	libros · 4	Año dos	Rechazar	año no numérico o con formato inválido	No es un año
4	libros · 5	Año MCMXLIX	Rechazar	año no numérico o con formato inválido	Aunque equivale a 1949, convertir numerales romanos no es una corrección mecánica
5	libros · 6	7 columnas	Rechazar	tiene 7 columnas, se esperaban 6	No se sabe cuál columna sobra
6	libros · 7	Autor vacío	Rechazar	autor vacío	El dato falta
7	libros · 8	ISBN vacío	Rechazar	ISBN vacío	Es la clave del libro

8	libros · 9	Ejemplares -3	Rechazar	cantidad de ejemplares negativa	Tomar el valor absoluto sería adivinar
9	lectores · 2	Documento ya existe (mismo correo, apellido con «(duplicado)»)	Rechazar	documento ya existe en el sistema	No se sobrescriben datos de un usuario existente desde una carga de altas
10	lectores · 3	Correo vacío	Rechazar	correo vacío	El correo es obligatorio y único
11	lectores · 4	Correo sin @	Rechazar	formato de correo inválido	No se puede reconstruir la dirección
12	lectores · 5	Teléfono tres-cero-cero	Rechazar	teléfono debe tener entre 7 y 15 dígitos	El teléfono es opcional, pero un valor presente y malformado hace dudosa la fila. Se aplica igual a todo teléfono no vacío
13	lectores · 6	Documento vacío	Rechazar	documento vacío	Es la clave natural y la contraseña inicial
14	lectores · 7	Nombres vacíos	Rechazar	nombres vacíos	El dato falta
15	propio · 7	ISBN repetido dentro del mismo archivo	Conservar la primera aparición, rechazar las demás	ISBN repetido en el archivo (línea 2)	Ninguna de las dos está aún en libro, así que el EXISTS no la ve; hay que compararlas entre sí
16	propio · 8	Año 2201 (futuro)	Rechazar	año fuera del rango 1450–2100	Año numérico pero imposible
17	propio · 9	Categoría vacía	Rechazar	categoría vacía	No se inventa una categoría «Sin categoría»; libro.id_categoria admite NULL, pero el catálogo se mantiene consistente

Casos que el grupo trata sin que aparezcan en los archivos: correo con otras mayúsculas (se normaliza con lower y cuenta como el mismo); ISBN con guiones (978-0-00…) se **rechaza** como no tiene exactamente 13 dígitos, no se corrige; un CSV con ; rechaza todas las filas con tiene 1 columnas, se esperaban N, la pista para revisar el separador.

4. CSV propio

Archivo: S14_libros_propio_con_errores.csv (8 filas de datos). 5 válidas que no están en la semilla (ISBN 97912345670xx) y 3 con errores que **no** aparecen en los archivos del curso.

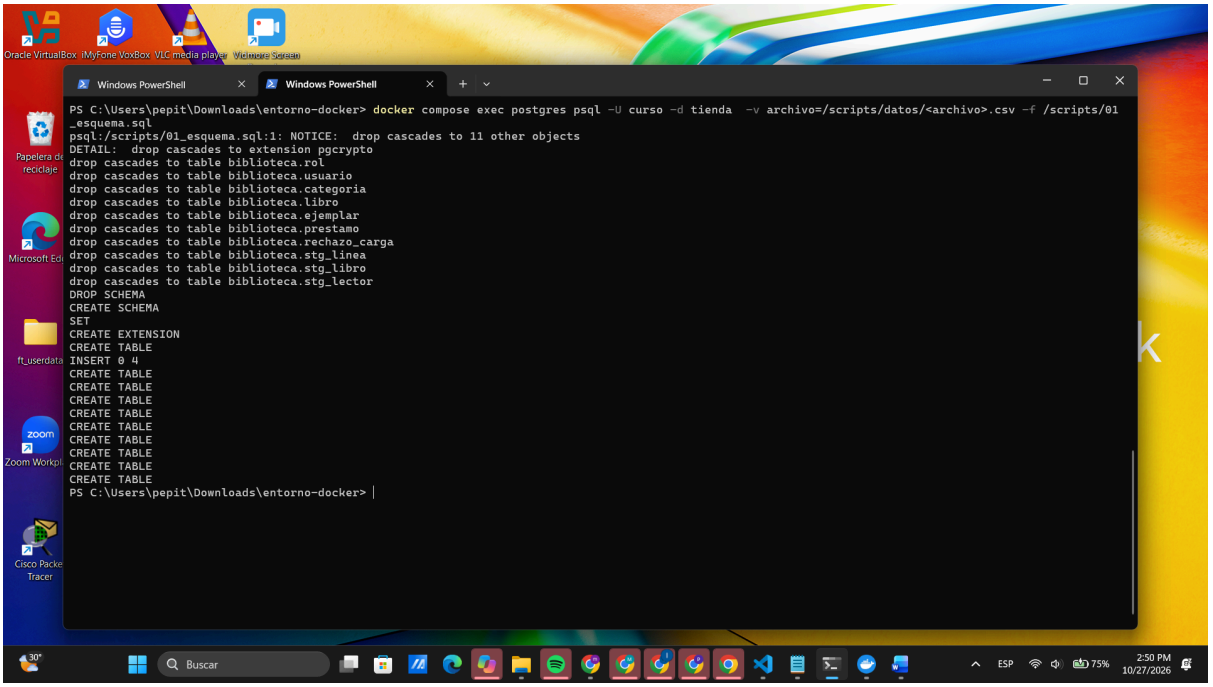
Línea	ISBN	Título	Año	Ej.	Resultado
2	9791234567001	La ciudad de los espejos	2021	2	Válida
3	9791234567002	Algoritmos cotidianos	2023	1	Válida
4	9791234567003	Memoria del rio	2019	3	Válida
5	9791234567004	El mapa de las estrellas	2022	0	Válida (libro sin copias)
6	9791234567005	Historias del Pacifico	2020	1	Válida
7	9791234567001	La ciudad de los espejos duplicada	2021	4	**Rechazada**: ISBN repetido en el archivo
8	9791234567006	Cronicas del futuro	2201	1	**Rechazada**: año fuera de rango
9	9791234567007	Libro sin categoria	2021	1	**Rechazada**: categoría vacía

Los tres errores son nuevos frente a los del curso: ISBN repetido *dentro* del archivo (el curso solo trae uno repetido contra el catálogo), año numérico fuera de rango (el curso solo trae años no numéricos) y categoría vacía.

5. Salidas de psql

Comando de cada carga, desde entorno-docker/:

docker compose exec postgres psql -U curso -d tienda -v archivo=/scripts/datos/<archivo>.csv -f /scripts/01_esquema.sq



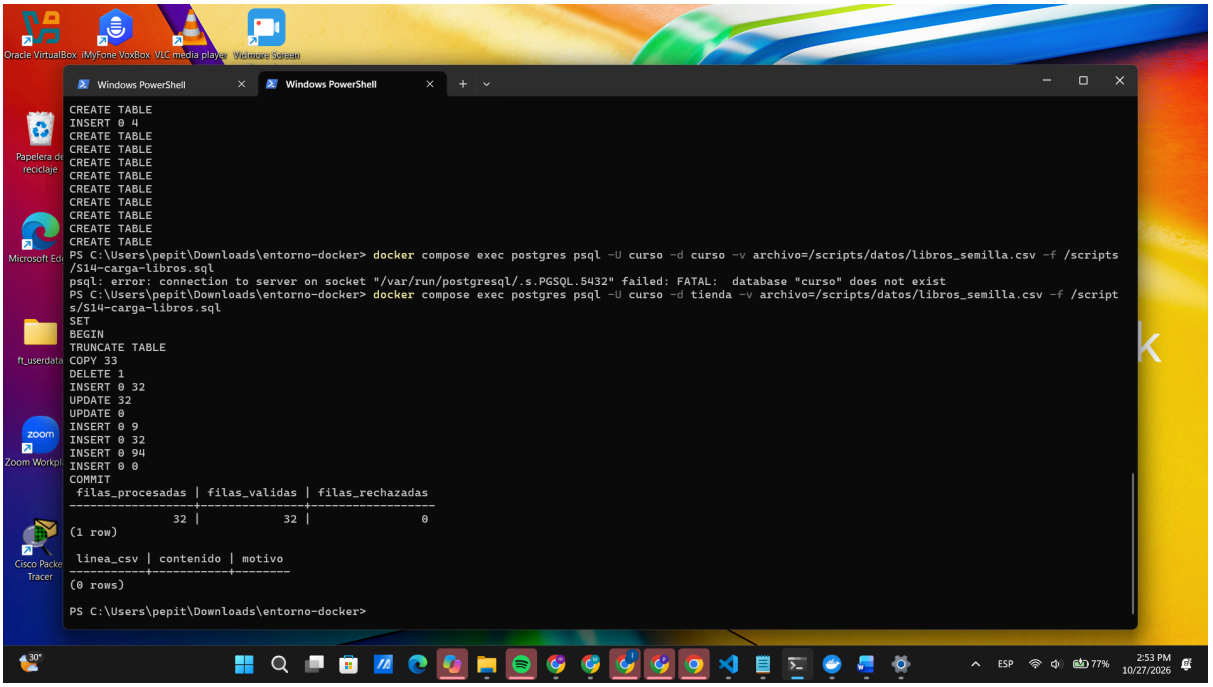
5.1 Libros limpio (libros_semilla.csv)

docker compose exec postgres psql -U curso -d tienda -v archivo=/scripts/datos/libros_semilla.csv -f /scripts/S14-carga-libros.sql

```
SET
 BEGIN
 TRUNCATE TABLE
 COPY 33
 DELETE 1
 INSERT 0 32
 UPDATE 32
 UPDATE 0
 INSERT 0 9
 INSERT 0 32
 INSERT 0 94
 INSERT 0 0
 COMMIT
  filas_procesadas | filas_validas | filas_rechazadas
 ------------------+---------------+------------------
                 32 |            32 |                0
 (1 row)

  linea_csv | contenido | motivo
 -----------+-----------+--------
 (0 rows)
```

32 libros, 9 categorías nuevas, 94 ejemplares.



5.2 Libros con errores (libros_semilla_con_errores.csv, tras la carga limpia)

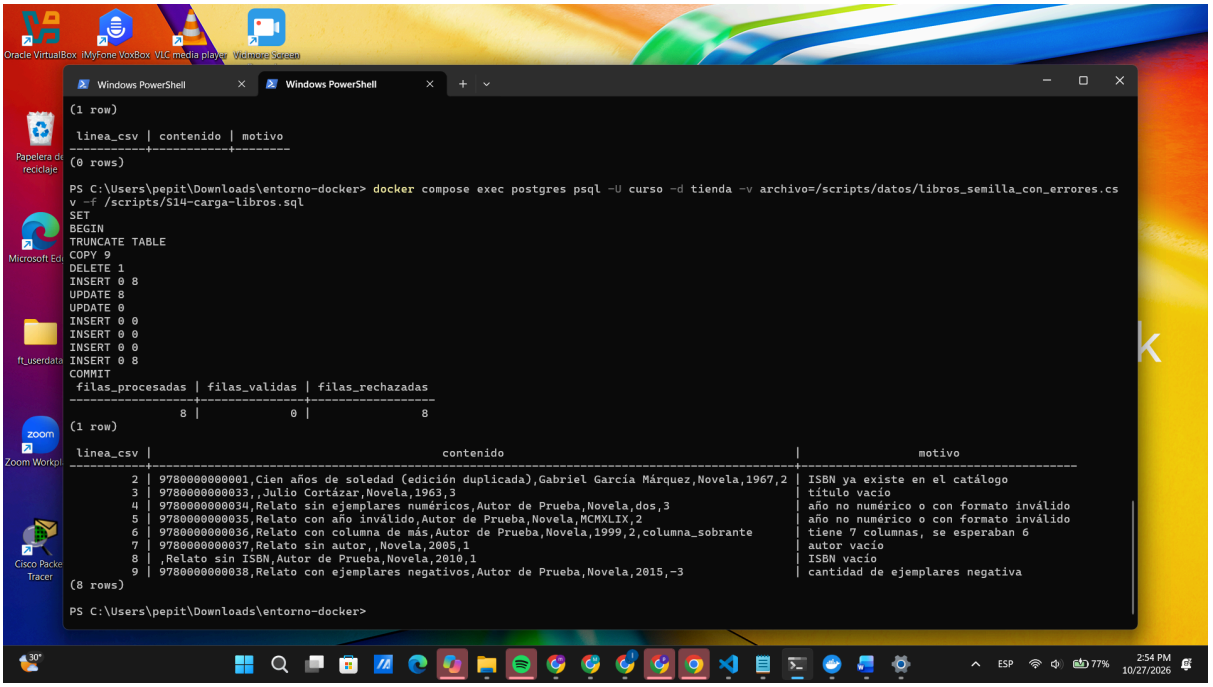
```
 filas_procesadas | filas_validas | filas_rechazadas
------------------+---------------+------------------
                8 |             0 |                8
(1 row)

  linea_csv |                                  contenido                                  |
motivo

-----------+---------------------------------------------------------------------------------------------+--------------
-------------------------
          2 | 9780000000001,Cien años de soledad (edición duplicada),Gabriel García
Márquez,Novela,1967,2 | ISBN ya existe en el catálogo
          3 | 9780000000033,,Julio Cortázar,Novela,1963,3                                 |
título vacío
          4 | 9780000000034,Relato sin ejemplares numéricos,Autor de Prueba,Novela,dos,3
          | año no numérico o con formato inválido
          5 | 9780000000035,Relato con año inválido,Autor de Prueba,Novela,MCMXLIX,2
          | año no numérico o con formato inválido
          6 | 9780000000036,Relato con columna de más,Autor de
Prueba,Novela,1999,2,columna_sobrante    | tiene 7 columnas, se esperaban 6
          7 | 9780000000037,Relato sin autor,,Novela,2005,1                               |
autor vacío
          8 | ,Relato sin ISBN,Autor de Prueba,Novela,2010,1                              |
ISBN vacío
          9 | 9780000000038,Relato con ejemplares negativos,Autor de
Prueba,Novela,2015,-3                    | cantidad de ejemplares negativa
 (8 rows)
```

Etiquetas de comando: COPY 9, UPDATE 8, UPDATE 0, tres INSERT 0 0 (categorías, libros, ejemplares), INSERT 0 8 (bitácora), COMMIT.

Observación sobre la línea 4. El título dice «sin ejemplares numéricos», pero en el archivo la palabra dos está en la columna del año (…,Novela,dos,3) y los ejemplares son 3. Por eso cae en la regla del año y no en la de ejemplares. Son igual 8 filas malas y 14 en total, pero la regla cantidad de ejemplares no numérica no se ejercita con los archivos del curso.

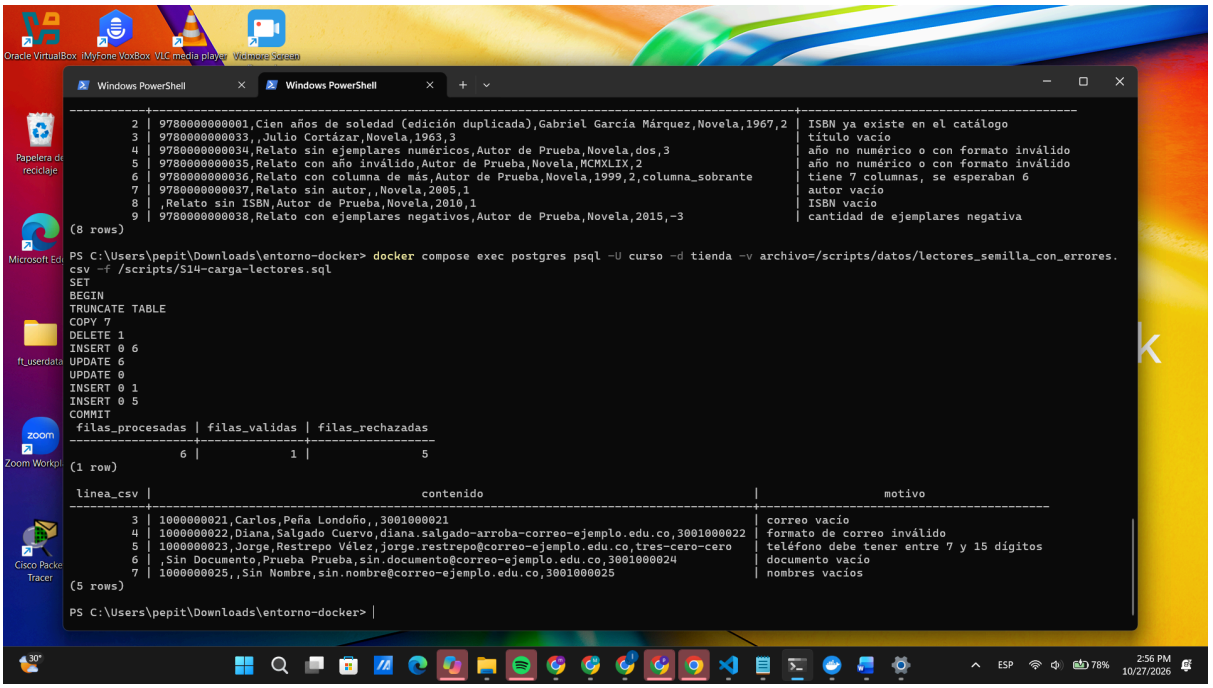


5.3 Lectores con errores (lectores_semilla_con_errores.csv, tras la carga limpia de lectores: INSERT 0 20)

```
 filas_procesadas | filas_validas | filas_rechazadas
------------------+---------------+------------------
                6 |             0 |                6
(1 row)

 linea_csv |                                  contenido                                  |                 motivo
-----------+-----------------------------------------------------------------------------+----------------------------------------
         2 | 1000000001,Mariana,Gómez Rojas (duplicado),mariana.gomez@correo-ejemplo.edu.co,3001000001 | documento ya existe en el sistema
         3 | 1000000021,Carlos,Peña Londoño,,3001000021                                  | correo vacío
         4 | 1000000022,Diana,Salgado Cuervo,diana.salgado-arroba-correo-ejemplo.edu.co,3001000022 | formato de correo inválido
         5 | 1000000023,Jorge,Restrepo
```

Vélez,jorge.restrepo@correo-ejemplo.edu.co,tres-cero-cero | teléfono debe tener entre 7 y 15 dígitos
6 | ,Sin Documento,Prueba Prueba,sin.documento@correo-ejemplo.edu.co,3001000024 | documento vacío
7 | 1000000025,,Sin Nombre,sin.nombre@correo-ejemplo.edu.co,3001000025 | nombres vacíos
(6 rows)



5.4 CSV propio (S14_libros_propio_con_errores.csv)

UPDATE 8
UPDATE 1
INSERT 0 2
INSERT 0 5
INSERT 0 7
INSERT 0 3
COMMIT
filas_procesadas | filas_validas | filas_rechazadas
------------------+--------------+------------------
8 | 5 | 3
(1 row)

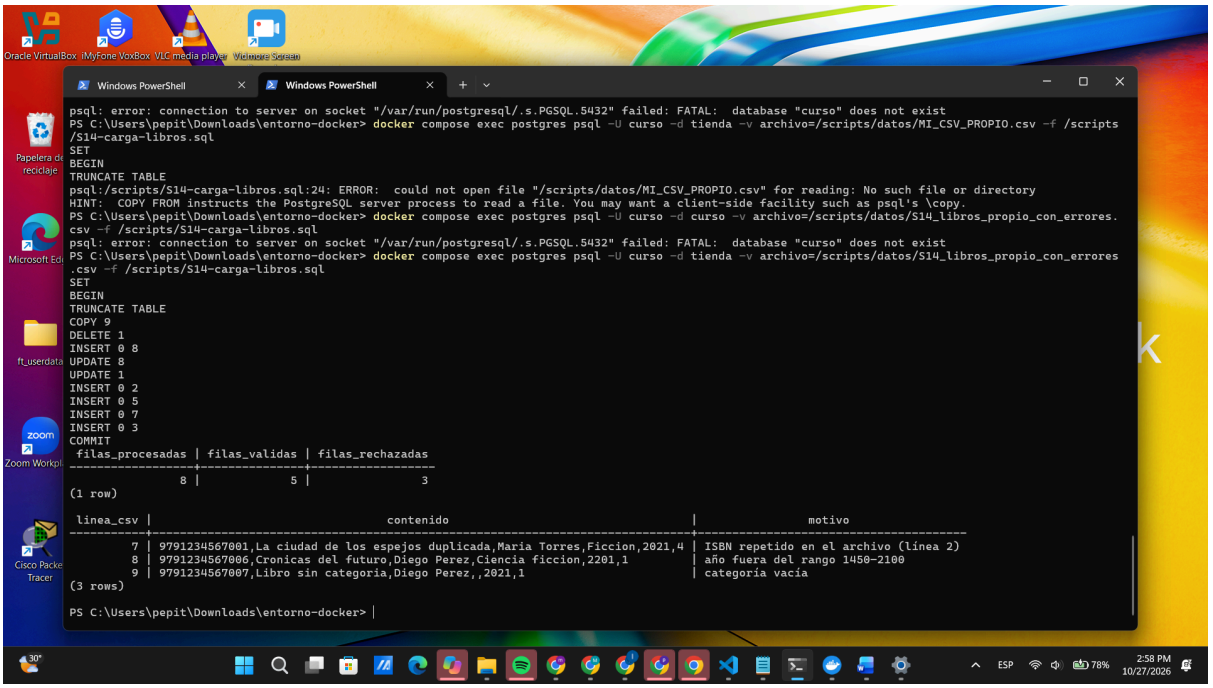
linea_csv | contenido | motivo

----------+----------+----------

7 | 9791234567001,La ciudad de los espejos duplicada,Maria Torres,Ficcion,2021,4 | ISBN repetido en el archivo (línea 2)
8 | 9791234567006,Cronicas del futuro,Diego Perez,Ciencia ficcion,2201,1 | año fuera del rango 1450–2100

9 | 9791234567007,Libro sin categoria,Diego Perez,,2021,1 | categoría vacía
(3 rows)

2 categorías nuevas (Ficcion, Informatica), 5 libros, 7 ejemplares (2+1+3+0+1). Estado final de la base: 37 libros, 101 ejemplares, 11 categorías, 20 lectores, 17 filas en la bitácora.



5.5 Repetibilidad

Al volver a cargar libros_semilla.csv sobre la base ya cargada, las 32 filas salen rechazadas con ISBN ya existe en el catálogo (INSERT 0 0 en categorías, libros y ejemplares). La carga se puede repetir sin duplicar nada. Lo mismo ocurre con lectores (documento ya existe en el sistema).

6. Prueba de la última línea de defensa

Se apaga **una** regla del CASE en una copia del script, se carga el archivo y se observa qué hace el esquema. Cada experimento parte de la base recién creada con libros_semilla.csv cargado.

#	Regla apagada	Archivo	Qué pasa	Demás filas	Bitácora
A	cantidad de ejemplares negativa (la del ejemplo	libros_semilla_con_errores.csv	**No choca con nada.** -3 pasa el ::INTEGER, el libro 9780000000038 entra y generate_series(1, -3) no	La carga termina con COMMIT: 1 válida, 7 rechazadas	7 filas (falta la del negativo)

	de la guía)		produce filas: queda un libro sin copias, indistinguible de uno con 0		
B	ISBN ya existe en el catálogo	libros_semilla_con_errores.csv	**Choca con la PK:** ERROR: duplicate key value violates unique constraint «libro_pkey» · Key (isbn)=(9780000000001) already exists	Con ON_ERROR_STOP el script se detiene y la transacción nunca llega a COMMIT: se deshace todo, también las filas válidas de ese mismo archivo	**Vacía**: el INSERT a rechazo_carga va en la misma transacción y se deshace con ella
C	ISBN repetido en el archivo	S14_libros_propio_con_errores.csv	**Choca con la PK** dentro del mismo INSERT (dos filas con 9791234567001)	Se pierden también las 4 válidas restantes; no entra ningún libro propio	Vacía, igual que en B

Respuesta. Cuando una fila mala llega a una restricción real (B, C), PostgreSQL aborta la sentencia y la transacción completa se deshace: no entra ninguna fila de esa carga, ni siquiera las válidas, y la bitácora queda sin los rechazos. Esa es la razón de envolver la carga en BEGIN … COMMIT (la base no queda a medias) y también de que la validación sea el primer filtro: sin ella, un solo dato malo bloquea el archivo entero y no deja registro de por qué. En cambio, una regla sin respaldo en el esquema (A) deja pasar el dato malo sin ningún aviso.

7. Hallazgo: el esquema no respalda varias reglas

El 01_esquema.sql actual solo tiene NOT NULL, UNIQUE, PRIMARY KEY, claves foráneas y la longitud de los VARCHAR. No tiene ningún CHECK. Consecuencias:

Regla de validación	¿Respaldada por el esquema?
ISBN no repetido / documento y correo únicos	Sí (PK y UNIQUE)

Título, autor, nombres vacíos (texto '')	No: NOT NULL no rechaza la cadena vacía (el script entrega '' tras el trim, no NULL)
ISBN de 13 dígitos	Parcial: VARCHAR(13) impide más de 13 pero no menos ni letras
Año entre 1450 y 2100	No (SMALLINT sin CHECK)
Ejemplares ≥ 0	No: el dato no se guarda, se convierte en filas

Si se quiere que la prueba de la sección 6 funcione como la describe la guía (el dato malo choca con un CHECK), el esquema necesitaría, por ejemplo: CHECK (titulo <> ''), CHECK (autor <> ''), CHECK (isbn ~ '^[0-9]{13}$') y CHECK (anio_publicacion BETWEEN 1450 AND 2100) en libro, y CHECK (numero_copia > 0) en ejemplar. Es una decisión del grupo; el documento no modifica el esquema.

https://github.com/fazemanuel/entorno-docker.git